

Datorlaboration 2

Måns Magnusson

16 januari 2015

Instruktioner

- Denna laboration ska göras **en och en**.
 - Det är tillåtet att diskutera med andra, men att plagiera eller skriva kod åt varandra är **inte tillåtet**.
 - Utgå från laborationsfilen som går att ladda ned [här](#)
 - Laborationen består av två delar:
 - Datorlaborationen
 - Inlämningsuppgifter
 - I laborationen finns det extrauppgifter markerade med *. Dessa kan hoppas över.
 - Deadline för labben framgår på [kurshemsidan](#)
-

Innehåll

I	Datorlaboration	3
1	Datastruktur: Matriser	4
1.1	Logiska matriser	5
1.2	Indexering av matriser	6
2	Datastruktur: data.frame	9
2.1	Skapa och undersöka en data.frame	9
2.2	Variabler i en data.frame	10
2.2.1	Skapa och ta bort variabler	10
2.2.2	Variabelnamn	11
2.2.3	Faktorvariabler	12
2.3	Indexera en data.frame	13
2.4	* Extraproblem	14
3	Grundläggande databearbetning	16
3.1	Kombinera data med rbind() och cbind()	16
3.2	Sammanfoga data med merge()	17
3.3	Aggregera datamaterial med aggregate()	17
3.4	str()	18
3.5	* Extraproblem	18
4	Datastruktur: Listor	20
4.1	Indexering av listor	21
4.2	* Extraproblem	22
5	Filhantering och grundläggande input och output (I/O)	23
5.1	Filhantering	23
5.2	.csv-filer och .txt-filer	24
5.3	.Rdata-filer	24
II	Inlämningsuppgifter	25
6	Inlämningsuppgifter	27
6.1	leap_year()	27
6.2	matrix_trace()	28
6.3	fast_stock_analysis()	28

Del I

Datorlaboration

Kapitel 1

Datastruktur: Matriser

Matriser är ytterligare en datastruktur som används flitigt i R. Den stora skillnaden mot vektorer är att vi har två dimensioner, rader och kolumner. Precis som vektorer kan vi bara ha en typ av värden i en matris. Det betyder att vi kan ha textmatriser, logiska matriser och numeriska matriser.

1. Skapa en matris enligt koden nedan. Studera matrisen, hur ser den ut?

```
x<-c(1,2,3,4,5,6)
min_matris1<-matrix(x,nrow=3,ncol=2)
```

2. Man behöver inte ange både hur många rader och kolumner matrisen ska ha. Anger man den ena räknar R ut den andra.

```
min_matris2<-matrix(x ,ncol=2)
```

3. Till skillnad mot andra matrisprogram som matlab (och i linjära algebra) så utförs alla operationer på matriser **elementvis** i R. Prova följande operationer på `min_matris`:
 - (a) Testa att multiplicera alla element med 10.
 - (b) Addera 3 till varje element.
 - (c) Dividera elementen med 4
 - (d) Beräkna resten (modulo) för elementen i matrisen om matrisen divideras med 2.
4. För att kombinera matriser till en blockmatris används `cbind()` (kombinera kolumnvis) och `rbind()` (kombinera radvis).
5. Nu ska du skapa en **större** matris. Skapa vektorerna `a`, `b`, `c` och `d` (se nedan). Sätt sedan samman dessa vektorer med `cbind()` till en matris.

```
a<-rep(c(1,2,3,4,5),10)
b<-1:50
c<-(1:50)^2
d<-log(1:50)
stor_matris <- cbind(a,b,c,d)
```

6. Vill vi skapa en textmatris gör vi ett liknande sätt som med numeriska matriser. Prova att skapa följande numeriska matris.

```
text <- c("Kalle", "Lisa", "Jonah", "Ghada")
mina_namn <- matrix(text, nrow=2, ncol=2)
```

7. Statistiska funktioner fungerar på matriser precis som på vektorer. Det R gör är att R först konverterar matrisen till en vektor och utför sedan beräkningen.

```
mean(min_matri1)
median(min_matri1)
sum(min_matri1)
sd(min_matri1)
var(min_matri1)
max(min_matri1)
min(min_matri1)
which.max(min_matri1) # Arg max
which.min(min_matri1) # Arg min
range(min_matri1)
```

8. Utöver dessa funktioner finns det dessutom en del funktioner som är specifika för just matriser (och `data.frames` längre fram). Vad innebär dessa funktioner?

```
ncol(min_matri1)
nrow(min_matri1)
dims(min_matri1)
```

1.1 Logiska matriser

Logiska matriser kan skapas på två sätt. Ett sätt är att skapa dem som vanliga numeriska matriser och textmatriser skapas. Det går också att använda relationsoperatorer på andra matriser (numeriska eller text) och då returneras en logisk matris.

1. Vi börjar med att skapa en logisk matris på samma sätt som övriga matriser.

```
x<-c(TRUE, TRUE, FALSE, TRUE, FALSE, TRUE)
A<-matrix(x, nrow=3)
```

2. Precis som som vi kan använda plus, minus m.m. för logiska matriser kan vi använda logiska operatorer på logiska matriser. Precis som för logiska matriser sker då operationerna **elementvis**. Prova följande kod.

```
y<-c(FALSE, TRUE, TRUE, TRUE, FALSE, TRUE)
B<-matrix(y, nrow=3)
A & B

      [,1] [,2]
[1,] FALSE TRUE
[2,]  TRUE FALSE
[3,] FALSE  TRUE

A | B
```

```

      [,1] [,2]
[1,] TRUE  TRUE
[2,] TRUE FALSE
[3,] TRUE  TRUE

!A

      [,1] [,2]
[1,] FALSE FALSE
[2,] FALSE  TRUE
[3,]  TRUE FALSE

```

3. Vi kan också använda relationsoperatorer för att skapa logiska vektorer. Precis som när det gäller vektorer sker dessa jämförelser elementvis. Det som returneras är en logisk matris. Prova följande kod:

```

X <- matrix(1:6, nrow=3)
Y <- matrix(6:1, nrow=3)
X > Y
X <= Y
X == Y

```

4. Att kombinera statistiska funktioner och logiska matriser är ett snabbt och enkelt sätt att pröva om exempelvis samtliga värden i en stor matris är korrekta. Vill vi pröva om alla element i `X` är större än 0 kan vi göra på följande sätt:

```

all(X > 0)

```

5. Använd relationsoperatorer för att skapa en logisk matris som indikerar alla element som är större än 20 i `stor_matris` ovan.

1.2 Indexering av matriser

För att indexera matriser och dataset behöver radindex OCH kolumnindex anges. Precis som vid vektorer används "hakparantes". Radindex anges först och sedan kolumnindex. De olika index separeras med ett komma. Lämnas ett index tomt innebär det att alla rader/kolumner väljs ut. Prova följande kod:

```

x <- 3:8
min_matris <- matrix(x, nrow=3, ncol=2)
min_matris

      [,1] [,2]
[1,]    3    6
[2,]    4    7
[3,]    5    8

min_matris[1,]

[1] 3 6

min_matris[,2]

[1] 6 7 8

min_matris[1:2,2]

```

```
[1] 6 7
min_matris[3,1]
[1] 5
min_matris[c(2,1),1]
[1] 4 3
```

En av de mindre bra egenskaperna i R är att väljs en rad eller kolumn ut reduceras detta automatiskt till en vektor. Vill vi inte att detta ska ske (om vi exempelvis vill räkna med en rad eller kolumnmatris) måste vi ange att matrisformatet ska behållas med argumentet **drop=FALSE**. Prova koden nedan.

```
min_matris[3, ,drop=FALSE]
      [,1] [,2]
[1,]     5     8
min_matris[,1 ,drop=FALSE]
      [,1]
[1,]     3
[2,]     4
[3,]     5
```

Precis som när det gäller vektorer kan vi använda index för att ändra enskilda element i en matris.

```
min_matris[2,1] <- 100
```

1. Prova att välja ut följande delar ur matrisen **storMat** ovan med `[,]`:
 - (a) Elementet (1, 4)
 - (b) Elementet (2, 1)
 - (c) Rad 2
 - (d) Kolumn 3
 - (e) Elementen (4, 4) och (2, 1)
 - (f) Rad 1 och 4
 - (g) Kolumn 1 till 3
2. Precis som med vektorer kan logiska värden användas för att välja ut värden. Stoppa då in en logisk matris av samma storlek i innanför hakparanteserna.

```
min_matris[min_matris < 2]
```

3. Prova på detta sätt att välja ut elementen i matrisen som är större än 5 och mindre än 3.
4. Ändra nu följande enskilda värden, rader och kolumner i **storMat** till 0.
 - (a) Elementen (4, 4) och (2, 1)
 - (b) Rad 1
 - (c) Kolumn 4
5. Nu ska vissa värden i matrisen **stor_matris** ändras. Alla värden som är mindre än 3 ska sättas till 0. Alla värden som är större än 45 ska sättas till NA.
[Tips! Gör detta i flera steg.]

6. Skapa vektorerna `y` och `z` och matriserna `rad_mat` och `kol_mat` på följande sätt:

```
y<-seq(4,11)
z<-c(rep(2,4),rep(9,4))
rad_mat<-rbind(y,z)
kol_mat<-cbind(y,z)
```

7. Studera dimensionerna på matriserna med funktionen `dim()`.
8. För att göra om en matris till en vektor används `as.vector()`. Pröva funktionen på `rad_mat` ovan.
9. För att ta bort rader eller kolumner från en matris används minustecknet.

```
kol_mat[-5,]

      y z
[1,]  4 2
[2,]  5 2
[3,]  6 2
[4,]  7 2
[5,]  9 9
[6,] 10 9
[7,] 11 9
```

10. Om vi tar bort allt så bara en rad- eller kolumnmatris kvarstår reduceras detta till en vektor. Detta kan undvikas med argumentet `drop = FALSE`:

```
kol_mat[,-1]

[1] 2 2 2 2 9 9 9 9

kol_mat[,-1 , drop = FALSE]

      z
[1,] 2
[2,] 2
[3,] 2
[4,] 2
[5,] 9
[6,] 9
[7,] 9
[8,] 9
```

11. Sammantaget kan man konstatera att det är samma principer för att indexera matriser som att indexera vektorer.

Kapitel 2

Datastruktur: data.frame

En `data.frame` är det vanligaste sättet att arbeta med statistiska data i R. Det är en stor tabell som innehåller ett antal variabler. I R är egentligen en `data.frame` bara en samling av lika långa vektorer (variabler) som är sammansatta som en lista (mer om detta senare). Det gör att en `data.frame` kan ha vektorer av olika typ (ex. text, numeriska, logiska m.m.).

2.1 Skapa och undersöka en data.frame

För att skapa en `data.frame` används funktionen `data.frame()` och i denna funktion lägger man till de variabler vi vill ha i vårt dataset som vektorer. Som vanligt måste man tillskriva datasetet till ett objektnamn med `<-`. Vill man namnge variablerna anger man variablerna som argument. För att titta på en hel `data.frame` skriver man bara namnet för det aktuella objektet.

```
minDF <- data.frame(num = 1:3, text = rep("Text", 3), logi=c(TRUE, TRUE, FALSE))
minDF
```

1. Skapa en `data.frame` som du kallar `minVecka` med vektorerna `myWeekdays`, `hours` och `tasks` på följande sätt:

```
days<-c("Monday", "Tuesday", "Wednesday", "Thursday", "Friday", "Saturday", "Sunday")
hour <- c(rep(8, 4), 6, 0, 0)
task <- c(rep("job", 4), "study", rep("fun", 2))
minVecka <- data.frame(myWeekdays = days, hours = hour, tasks = task)
```

2. Prova att skapa samma `data.frame` fast utan att ange variabelnamnen. Vad blir då de automatiska variabelnamnen?
3. I R finns det ett antal datamaterial förinstallerade med R. För att läsa in dem används funktionen `data()`. Läs på detta in datasetet `iris` och studera vad materialet innehåller.

```
data(iris)
iris
```

4. Vill vi få mer information om `iris` kan vi titta i dokumentationen med `?iris`.
5. För att se vilka `data.frames` som är förinstallerade med R kan vi använda följande kod:

```
library(help = "datasets")
```

6. Prova att läsa in en annan `data.frame` som verkar intressant och titta på materialet.

7. Ofta vill vi studera vår `data.frame` mer noggrant avseende innehåll. I “Enviroment”-fönstret i R-Studio går det att klicka för att titta på en given `data.frame`. Studera den `data.frame` som du precis läst in (`iris`) på detta sätt i R-Studio.
8. Utöver detta finns ett antal funktioner som är relevanta att använda. Pröva följande funktioner på `iris`.
 - (a) Funktionerna `head()` och `tail()`. Pröva att använda argumentet `n`.
 - (b) Funktionerna `summary()` och `str()`.
 - (c) Funktionerna `dim()`, `ncol()` och `nrow()`.
 - (d) Funktionerna `names()`, `colnames()` och `rownames()`.
 - (e) Spara antalet kolumner som `antKolumn` och antalet rader som `antRader` med hjälp av `ncol()` och `nrow()`.

2.2 Variabler i en `data.frame`

Det är sällan så att vi är intresserade av en hel `data.frame`. Istället är det enskilda variabler vi är intresserade av att analysera och använda i olika analys-sammanhang. I R görs detta genom att vi väljer ut en enskild variabel (som då blir en vektor). Sedan kan vi använda vilka statistiska funktioner vi vill för deskriptiv statistik.

För att “plocka ut” en variabel från en `data.frame` kan vi göra på flera sätt:

```
iris$Sepal.Width
iris[["Sepal.Width"]]
iris[, "Sepal.Width"]
iris[, 2]
```

I R kan vi jobba med flera `data.frames` samtidigt. Därför måste vi i varje steg ange vilken `data.frame` vi arbetar med. I de första tre fallen använder vi variabelnamnet och den sista metoden använder vi vilken kolumn som är variabeln av intresse. Hakparanteser används här för att “indexera” variabler, mer om detta senare.

Det går självklart också att spara en enskild variabel och då sparas den som en vektor.

```
mySepalWidth <- iris$Sepal.Width
```

1. Pröva att plocka ut variabeln `Species` från `iris` med de tre angivna metoderna ovan.
2. Pröva att göra följande analyser med hjälp av de statistiska funktionerna för vektorer.
 - (a) Vad är medianen för `Petal.Length`? [**Tips!** `median()`]
 - (b) Vad är variansen för `Sepal.Length`? [**Tips!** `var()`]
 - (c) Skapa en frekvenstabell för variabeln `Species`. [**Tips!** `table()`]
 - (d) Använd relationsoperatorer för att beräkna medelvärdet avseende `Sepal.width` för arten (`Species`) “setosa”. [**Tips!** `mean()`], Börja med att skapa en logisk vektor med hjälp av relationsoperatorer, du kan också börja med att spara ned vektorn innan.].
 - (e) Vad är decilerna för `Petal.Width`? [**Tips!** `quantiles()`]
 - (f) Vilka är de tre första värdena i `Sepal.Width`?

2.2.1 Skapa och ta bort variabler

För att skapa en ny variabel tillskriver vi den nya variabeln (d.v.s. variabelnamnet) en ny vektor av samma längd som den aktuella `data.frame`. Vill vi skapa en ny variabel som är kvoten mellan `Petal.Width` och `Petal.Length` i `iris` gör vi på följande sätt:

```
iris$newVariable <- iris$Petal.Width / iris$Petal.Length
```

1. Skapa en ny variabel som är summan av `Petal.Width` och `Sepal.Width` samt en variabel som är differensen mellan `Sepal.Length` och `Petal.Length`.
2. I vissa fall vill vi skapa nya kategoriska variabler. Detta kan vi göra på olika sätt. I exemplet nedan vill vi dela in `Petal.Width` i tre delar. Mindre än 1, mellan 1 och 2 och mer än 2. Antingen kan vi göra det "manuellt" på följande sätt (nu skapar vi en textvariabel, men det går lika gärna att skapa en numerisk variabel):

```
iris$newCat <- "- 1"  
iris$newCat[iris$Petal.Width >= 1] <- "1 - 2"  
iris$newCat[iris$Petal.Width > 2] <- "2 +"
```

3. Gå igenom koden ovan och se vad som händer i varje steg. Rent faktiskt indexerar vi en del av variabeln med hakparantesen och relationsoperatoren och tillskriver denna del av vektorn ett visst värde. Att göra det manuellt kan tyckas onödigt, men i många fall kanske vi vill göra mindre korrigeringar av variabler och då är detta sätt ofta enkelt.
4. Vill vi bara skapa en kategorisk variabel kan vi använda funktionen `cut()`. För att använda funktionen `cut()` behöver vi definiera hur kategoriseringen ska göras. Vad är skillnaden mellan de två sätten nedan?

```
iris$newCat2 <- cut(iris$Petal.Width, breaks=2)  
iris$newCat3 <- cut(iris$Petal.Width, breaks=c(1, 2, Inf))
```

5. För att ta bort en variabel tillskriver vi variabeln värdet `NULL`. Detta innebär att variabeln raderas. Prova att ta bort de variabler du skapat tidigare.

```
iris$newCat2 <- NULL
```

2.2.2 Variabelnamn

Ibland vill vi ändra ett variabelnamn vi skapat. Variabelnamn i `data.frames` kan i princip se ut hur som helst, dock får de inte börja med en siffra. För att det ska vara enkelt att arbeta med dem är det bra om de följer samma regler som variabelnamn för objekt (d.v.s. inte innehålla mellanslag).

1. För att ta reda på variabelnamnen i en `data.frame` används funktionen `names()`. Det som returneras är en textvektor. Prova att använda funktionen på `iris`. Spara ned variabelnamnen som textvektorn `namn`.
2. Vill vi ändra variabelnamnen tillskriver vi dem ett nytt värde. Om vi exempelvis vill byta alla variabler i `iris` gör vi det genom att "byta ut" den textvektor som innehåller variabelnamnen på följande sätt.

```
names(iris) <- c("var1", "var2", "var3", "var4", "var5")
```

3. Prova att byta ut alla variabler utom en med godtyckliga variabelnamn. Vad får den variabel som du inte namngav för `namn`?
4. Använd vektorn `namn` som du sparade ovan för att återställa variabelnamnen till de `namn` de hade innan. Kontrollera att namnen är "tillbaka" med `names()`.

5. Vi vet nu hur vi kan ändra samtliga variabler och att variabelnamn fungerar som vanliga textvektorer. Det gör att vi använder samma princip för att ändra enskilda element i en vektor för att ändra ett enskilt variabelnamn.

```
names(iris)[2] <- "variabel2"
names(iris)[c(1,5)] <- c("var1", "var5")
```

6. Prova att byta ut variabelnamnet på de variabelnamn vars variabelnamn inte har bytts ut ovan. Döp dem till godtyckliga variabelnamn.
7. Återställ än en gång variabelnamnen för `iris` med hjälp av textvektorn `namn`.

2.2.3 Faktorvariabler

En speciell typ av variabler är så kallade faktorvariabler, `factor`. I R ser dessa variabler nästan ut som textvektorer. Skillnaden syns om vi använder `typeof()`. Då framgår att en faktorvariabel är av typen `integer`, inte `character`.

Faktorvariabler har två syften, dels att spara minne (heltal tar betydligt mycket mindre utrymme i minnet än textvektorer) och dels kan dessa variabler användas direkt i analysfunktioner som ex. linjär regression och då hanteras de korrekt (med dummyvariabler). Det gör att det ofta kan vara värdefullt att konvertera klassvariabler till faktorvariabler.

1. För att skapa en faktorvariabel använder vi `factor()`.

```
myText <- paste("Text", 1:5)
myFactor <- factor(myText)
```

2. Hur ser man skillnad på en textvektor och en faktorvariabel ovan?
3. Skapa en faktorvariabel som ser ut på följande sätt som du kallar `minFaktor` [Tips! `rep()`]:

```
[1] a a a a a a b b b c c c c
Levels: a b c
```

4. I de fall vi vill använda faktorvariabler i exempelvis en linjär regression blir den första klassen referensklassen. Vill vi ändra referensklass gör vi på följande sätt:

```
myFactor <- relevel(myFactor, ref=3)
```

5. Ändra referensklassen för `minFaktor` till `'b'`.
6. Skapar vi en ny `data.frame` som innehåller en textvektor kommer textvektorn automatiskt översättas till en faktorvariabel. För att undvika detta måste man ange argumentet `stringsAsFactors=FALSE`.

```
myText <- paste("Text", 1:5)
myDataFrame1 <- data.frame(text=myText)
myDataFrame2 <- data.frame(text=myText, stringsAsFactors=FALSE)
```

7. Skapa en ny `data.frame` som du kallar `minDF`. Den ska innehålla `minFaktor`, både som textvektor och som faktorvariabel.

8. Vill vi byta en eller flera “etiketter” i en faktorvariabel gör vi det på ett liknande sätt som vi byter variabelnamn. Med funktionen `level()` får vi tillgång till de olika kategorierna som en textvektor. Precis som för variabelnamn kan vi använda detta för att ändra klassetiketter:

```
level(myFactor)
level(myFactor)[1] <- "Ny label"
```

9. Ändra etiketterna “a” och “c” i `minFaktor` ovan till “first” och “last”.
10. Då faktorvariabler “under the hood” är en heltalsvektor kan konverteringar ibland bli förvirrande. Konverterar vi en faktorvariabel till numerisk variabel blir den denna underliggande heltalsvektor. Vill vi få tillgång till klassetiketterna måste vi konvertera faktorvariabeln till en textvektor. Prova `as.numeric()` och `as.character()` på `minFaktor`.
11. Faktorvariabler motsvarar nominala variabler. Vi kan också skapa ordinala variabler med funktionen `factor()` om vi anger argumentet `ordered=TRUE`. Automatisk kommer ordningen vara sorterat efter de olika klasserna sett som text. Se exempel nedan (och notera klass “10”).

```
myFactor <- factor(as.character(1:10), ordered=TRUE)
myFactor[1] > myFactor[10]

[1] FALSE
```

12. Skapa en ny version av `minFaktor`, men gör den till en “ordered factor”. Prova att jämför olika värden med relationsoperatorer.

2.3 Indexera en data.frame

För att indexera en `data.frame` (eller välja ut subset) behöver både radindex **OCH** kolumnindex anges. Precis som vid vektorer används “hakparantes”. Radindex anges först och sedan kolumnindex. Tänk matriser. De olika index separeras med ett komma. Lämnas ett index tomt innebär det att alla rader/kolumner väljs ut.

1. Prova följande kod med vårt dataset `iris`.

```
data(iris)
iris[1,]
iris[,2]
iris[1:2,2]
iris[3,1]
iris[c(2,1),1]
```

2. En av de mindre bra egenskaperna i R är att väljs en rad eller kolumn ut reduceras detta automatiskt till en vektor. Vill vi inte att detta ska ske (om vi exempelvis fortfarande vill ha en `data.frame`) måste vi ange att formatet ska behållas med argumentet `drop=FALSE`.

```
iris[, 2, drop=FALSE]
iris[1:2, 2, drop=FALSE]
```

3. Läs in datamaterialet `faithful` med `data(faithful)`. Använd `?faithful` för att läsa på om datamaterialet. I denna `data.frame`, välj ut följande element:

- (a) Värdet på rad 2 för variabeln `eruptions`

- (b) Rad 2
 - (c) Variabeln `waiting` (se till att det fortfarande är en `data.frame`)
 - (d) Rad 1 och 4
4. Precis som med vektorer kan vi välja ut rader och kolumner med logiska vektorer. Med relationsoperatorer kan vi därför plocka ut en delmängd av observationerna.

```
logi <- iris$Petal.Width > 1
newiris <- iris[logi, ]
```

5. Använd relationsoperatorer för att välja ut de observationer med en `eruptions` som är längre än 2 minuter. Spara det nya datat som `newGeyser`.
6. Precis som för vektorer i almänhet kan vi ändra värden i enskilda vektorer i en `data.frame`. Vill vi ändra alla värden i `Petal.Width` som är mindre än 1 till 0 gör vi bara på följande sätt:

```
iris[iris$Petal.Width < 1, "Petal.Width"] <- 0
```

7. Så vad gjordes ovan? Först valde vi ut de observationer som är mindre än 1. Därefter valde vi ut variabeln `Petal.Width` och tillskriver alla dessa element värdet 0.
8. Ändra på ett liknande sätt följande i `faithful`.
- (a) Den första raden till 1.
 - (b) Det sista elementet i `eruptions` till 100. [**Tips!** `length()`]
 - (c) Alla värden större än 80 i `waiting` till 100. [**Tips!** relationsoperatorer]
9. För att ta bort rader eller variabler kan vi använda minustecknet, precis som för vektorer. Vill vi ta bort första och sista raden i `iris` kan vi göra på följande sätt.

```
iris <- iris[- c(1, nrow(iris)), ]
```

10. Prova att ta bort rad 1 till 10 i `faithful`.
11. Nu kommer också funktionen `order()` till rätta. Med `order` får vi ut en vektor med index sorterade i storleksordning efter en vektor/variabel. Vill vi exempelvis sortera `iris` efter `Petal.Length` gör vi på följande sätt:

```
iris <- iris[order(iris$Petal.Length), ]
iris <- iris[order(iris$Petal.Length, decreasing = TRUE), ]
```

12. Prova att sortera `faithful` på samma sätt efter variabeln `waiting` i fallande ordning.

2.4 * Extraproblem

1. Utgå från det förinstallerade datamaterialet `rock` och läs in detta dataset med `data()`. Vi ska nu åtgå från detta datamaterial och genomföra ett antal operationer.
- (a) Börja med att skapa en ny variabel du kallar `new_shape`. Den ska beräknas på följande sätt:

$$\text{new_shape} = \frac{\text{peri}}{\sqrt{\text{area}}}$$

- (b) Jämför denna nya variabel med den gamla variabeln `shape`.
- (c) Skapa en normaliserad version av variabeln `peri`. D.v.s.

$$y = \frac{x - \bar{x}}{sd(x)}$$

där x är `peri` och y är `norm_peri`.

Kapitel 3

Grundläggande databearbetning

Inte sällan behöver vi kombinera data från flera olika `data.frames`, matriser, vektorer på olika sätt. Många gånger är själva databearbetningarna som tar tid att göra innan vi kan påbörja de analyser vi är intresserade av. Följande manipulationer hör till de vi vanligen kan tänkas vilja göra.

Funktion	Beskrivning
<code>rbind()</code>	Kombinerar <code>data.frames</code> radvis.
<code>cbind()</code>	Kombinerar <code>data.frames</code> kolumnvis.
<code>merge()</code>	Kombinerar två <code>data.frames</code> med en ID-variabel
<code>aggregate()</code>	Aggregerar uppgifter efter ID-variabel

1. Vi börjar med att återigen läsa in våra dataset `geyser` och `iris`.

```
data(iris)
data(faithful)
```

3.1 Kombinera data med `rbind()` och `cbind()`

1. För att kombinera två `data.frames` radvis behöver databasen ha exakt samma variabler för att det ska fungera. Ett exempel ges nedan med `iris`. Om vi vill lägga ihop två de första tio raderna i `iris` och de sista 10 raderna gör vi på följande sätt:

```
upper10 <- iris[1:10, ]
lower10 <- iris[11:20, ]
newIris <- rbind(upper10 , lower10)
```

2. Prova att på ett liknande sätt kombinera de första 5 raderna och de sista 5 raderna i `faithful`.
3. Vill vi istället lägga ihop två `data.frames` kolumnvis gör vi det med `cbind()`. För att detta ska gå måste de `data.frames` vi vill lägga ihop både vara lika långa OCH vara sorterade på samma sätt. Med `cbind()` slås just bara två `data.frames` ihop kolumnvis, ingen hänsyn tas till ordningen. Nedan är ett exempel:

```
newIris <- cbind(upper10 , lower10)
```

4. Prova att göra samma sak med datamaterialet `faithful`.

3.2 Sammanfoga data med merge()

En av de viktigaste funktionerna för datamanipulation i R är `merge()`. Med denna funktion kan vi kombinera två `data.frames` baserat på en eller flera ID-variabler. Detta är centralt när vi samkör olika `data.frames`.

1. Vi börjar med att skapa två `data.frames` som exempel. Skapa dessa med följande kod (det vi gör är att vi kör exemplen till funktionen `merge()` utan att skriva ut all kod):

```
example("merge", echo = FALSE)
```

2. Kontrollera att du nu har två dataset i din globala miljö. Ett som heter `authors` och ett som heter `books`. Titta på dessa dataset så du vet vad de innehåller.
3. Vi har nu två `data.frames` att arbeta med, en med böcker och en med författare. Vill vi nu kombinera dessa använder vi oss av `merge()`. Funktionen har argumenten `x` och `y` som är de två dataset vi vill kombinera. Vi behöver också ange vilka variabler vi ska använda som ID-variabler argumentet. Vill vi slå ihop `authors` med `books` gör vi på följande sätt:

```
res1 <- merge(x=authors, y=books, by.x = "surname", by.y = "name")
```

4. Titta på `res1` och se hur sammanslagningen har gjorts.
5. Prova nu att istället slå ihop `books` med `authors`.
6. I exemplet ovan får vi inte med ‘‘R core’’ då de inte finns med i båda `data.frames`. Vill vi få med allt i båda datamaterialen kan vi använda argumentet `all=TRUE`.

```
res1 <- merge(x=authors, y=books, by.x = "surname", by.y = "name", all=TRUE)
```

7. Ibland kanske vi inte vill få med alla ID från båda materialen utan bara från ett. För detta använder vi `all.x=TRUE` (för `data.frame` som anges som `x`) och `all.y=TRUE` motsvarande. Prova att kombinera `authors` och `books` med dessa två argument. Prova att kombinera de två datamaterialen med dessa argument. När får du med ‘‘R Core’’ i det kombinerade materialet?

3.3 Aggregera datamaterial med aggregate()

1. Vill vi aggregera delar av ett material använder vi funktionen `aggregate()`. Vi behöver ange vilket material vi vill aggregera, efter vilken eller vilka ID-variabler (inlagda som en lista) samt vilken funktion vi vill använda för att aggregera. Vill vi ‘‘skicka med’’ ytterligare argument till aggregeringsfunktionen lägger vi bara till dessa efter de övriga argumenten.

```
data(iris)
myAggr1 <- aggregate(x=iris$Sepal.Length, by=list(iris$Species), FUN=median)
myAggr2 <- aggregate(x=iris$Sepal.Length, by=list(iris$Species), FUN=length)
myAggr3 <- aggregate(x=iris$Sepal.Length, by=list(iris$Species), FUN=mean, rm.na=TRUE)
```

2. * Tänk på att det som händer inuti R är att varje variabel (sett som en vektor) delas upp efter `by`-variablerna. Sedan används funktionen som anges till `FUN` på varje uppdelad vektor. Det gör att vi kan skapa egna funktioner som vi sedan använder i `aggregate()`. Prova koden nedan.

```
mean_median <- function(x) (mean(x) + median(x)) / 2

myAggr4 <- aggregate(x=iris$Sepal.Length, by=list(iris$Species), FUN=mean_median)
```

3.4 str()

För att undersöka objekt (vilket som helst) i R finns funktionen `str` (från internal **structure**). Det är helt enkelt ett sätt att “titta in” i godtyckliga objekt och se hur de ser ut.

1. Prova `str()` på ett antal av de objekt du skapat ovan.

```
x <- 1:10
str(x)

int [1:10] 1 2 3 4 5 6 7 8 9 10

str(iris)

'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species      : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...

str(myAggr1)

'data.frame': 3 obs. of 2 variables:
 $ Group.1: Factor w/ 3 levels "setosa","versicolor",...: 1 2 3
 $ x      : num  5 5.9 6.5
```

3.5 * Extraproblem

1. Utgå från det förinstallerade datamaterialet `mtcars` och läs in detta dataset. Vi ska nu åtgå från detta datamaterial och genomföra ett antal operationer.
 - (a) Börja med att skapa en ny variabel du kallar `carName`. Den ska innehålla namnen på bilarna och ska vara en textvektor (inte en faktorvariabel).
 - (b) Gör om variabeln som beskriver huruvida bilen har automatisk eller manuell växellåda till en faktorvariabel med etiketterna “Automatisk” och “Manuell”.
 - (c) Skapa en ny kategorisk variabel som delar in bilar efter om de har fler eller färre än 130 (brutto) hästkrafter. Kalla variabeln `hpCategory`. Använd funktionen `table()` för att skapa en korstabell mellan dina två nya variabler. Nedan framgår “facit”.

am	hpCategory	
	HP <= 130	HP > 130
Automatic	7	12
Manual	10	3

- (d) Utgå nu från variabeln `hpCategory` ovan och beräkna medelvärde för variabeln `mpg` efter vilken typ av växellåda bilen har. Ta dock bort de tre snabbaste bilarna (sett efter “1/4 mile time”) innan du beräknar medelvärde. Döp om den nya variabeln till `amMpg`.

- (e) Gör på ett liknande sätt och beräkna den genomsnittliga vikten för bilarna efter både kategorin `hpCategory` och typ av växellåda med `aggregate()`. Döp om den nya aggregerade variabeln till `meanWeight`.
- (f) Lägg nu till de nya variabler du skapat till det ursprungliga datamaterialet med `merge()`.

Kapitel 4

Datastruktur: Listor

Listor är en mer generell datastruktur i R. En lista är en struktur där varje element kan vara en godtycklig annan datastruktur. Om vi exempelvis vill arbeta med 100 olika vektorer kan vi kombinera dem till en lista. Listor används ofta för att spara mer komplexa objekt i R där vi vill ha flera olika typer av datastrukturer. En `data.frame` är egentligen en lista i grund och botten som består av ett antal vektorer som är ordnade på samma sätt.

1. Antag att du har vektorer med de veckodagar som du behöver arbeta hårt, arbeta (mindre hårt) och har fri tid. Samt hur många timmar du ska arbeta hårt totalt.

```
hard_work <- c("Monday", "Tuesday", "Wednesday", "Thursday")
work <- "Friday"
free <- c("Saturday", "Sunday")
hardwork_hours <- c(2, rep(4, 3), 6, 0, 0)
```

2. Skapa en lista med vektorerna `hard_work`, `hours`, `job` och `free` och döp den till `weekPlan`. Skapa listan nedan:

```
weekPlan <- list(hard_work, hardwork_hours, work, free)
```

3. Precis som med variabler i `data.frames` kan vi namnge listornas element. Skapa listan nedan:

```
weekPlan_with_names <- list(hwork=hard_work, hours=hardwork_hours, work=work, free_time=free)
```

4. Undersök de två listor du skapat ovan med funktionerna `summary()` och `length()`. Vad är den stora skillnaden dem emellan?
5. Använd funktionen `names()` för att undersöka elementens namn.
6. Precis som i `data.frames` kan vi ändra namnen enkelt med indexering. Prova att lägga till namn till `weekPlan` baserat på exemplet nedan:

```
names(weekPlan)[1] <- "HardWorkName"
```

7. För att lägga till ett element i en lista gör vi precis som med en vanlig vektor med `c()`.

```
myList <- list("Hej", c(TRUE, FALSE))
c(myList, list(1:5))
```

```
[[1]]
[1] "Hej"

[[2]]
[1] TRUE FALSE

[[3]]
[1] 1 2 3 4 5
```

8. Prova att lägga till textelementet 'my note' sist i listan `weekPlan` och döp listelementet där `note` ligger till `myNote`.
9. Har vi en lista med flera vektorer kan vi lägga ihop dessa vektorer med `unlist()`.

```
num_list <- list(3:5, 10:15, 1, 20:22)
num_list
unlist(num_list)
```

4.1 Indexering av listor

Precis som med vektorer kan vi indexera listor. Dock kan det vara två saker vi vill göra. Antingen vill vi välja ut element i en lista (men fortsatt behålla objektet som en lista) eller så vill vi välja ut det objekt som ligger i listan.

För att välja ut en del av en lista (men fortfarande som en lista) används som vanligt hakparantes.

Vill vi däremot välja ut objektet **inne i** listan används dubbel hakparantes. Då kan vi dock bara välja ut ett enda objekt i taget.

1. Skapa listan `minLista`:

```
minLista <- list("Hej", 1:10, c("Hej", "Karlsson"))

minLista[1]
minLista[[1]]
minLista[1:2]
minLista[[1:2]]
minLista[-1]
```

2. Välj `work` från `weekPlan` med `[[]]`.
3. Prova att välja det första och andra listelementet från `weekPlan` med `[]`.
4. Precis som med vektorer kan vi ändra element i en lista genom att använda hakparanteser:

```
minLista[[1]] <- "K2"
minLista
minLista[2:3] <- list(hejsan=c(1,2,3), TRUE)
minLista
minLista[1] <- NULL
minLista
```

5. Radera nu `note` från listan `weekPlan`.

4.2 * Extraproblem

1. Läs in datamaterialet `faithful`. [**Tips!** `data()`]
Baserat på detta dataset. Plocka ut de enskilda variablerna i `faithful` och spara dem som enskilda element i en lista. Undersök vilka sätt att “välja ut” variabler i en `data.frame` som också fungerar för en lista.
2. Läs in datamaterialet `mtcars`. Skapa en ny lista du kallar `fuel`.
 - (a) Spara bilarnas namn som en textvektor. Kalla listelementet `namn`.
 - (b) Beräkna den genomsnittliga bränsleförbrukningen för alla bilar och spara detta i ett element du kallar `meanMPG`. Nedan framgår rätt resultat:

```
[1] 20.091
```

- (c) Spara sedan hela datamaterialet som ett element du kallar `data`. Ta dock bort de bilar som har en automatisk växellåda.
 - (d) Utgå från det data du sparar i listan ovan och beräkna den genomsnittliga bilvikten och spara detta i ett nytt element du kallar `meanWeight`. Nedan framgår vad du borde få för värde:

```
[1] 2.411
```

- (e) Ta bort elementet `meanMPG`.

Kapitel 5

Filhantering och grundläggande input och output (I/O)

Det är mycket sällan vi har nytta av de inbyggda datamaterialen i R, utan i de flesta fall behöver vi läsa in data från olika filformat. Detta brukar kallas I/O eller input och output.

För att läsa och skriva till filer utanför R behöver vi börja med att lära oss hur R kommunicerar med operativsystemets filsystem. Detta kan skilja sig mellan olika operativsystem hur det ser ut.

5.1 Filhantering

1. Använd funktionen `getwd()` för att se vilket som är ditt nuvarande “working directory” på datorn. Nedan är mitt working directory. Tänk på att en sökväg bara är ett textelement.

```
getwd()
```

```
[1] "/Users/manma97/Dropbox/Doktorandstudier/Undervisning/Statistisk programmering i R/KursRprgm"
```

2. Med funktionen `dir()` kan vi se vilka filer som finns i den aktuella katalogen. Stämmer det med vad du väntar dig?

```
dir()
```

3. Spara resultatet (textelement) i variabeln `myOldDir`.

```
minSokvag <- getwd()
```

4. Välj en katalog du vill arbeta i och skriv ned sökvägen som ett textelement och spara som `mittWorkingDirectory`.
[**Tips:** I R (och flera andra programmeringsspråk) har tecknet `\` en särskild betydelse, vill du skapa en sökväg behöver du antingen använda `/` eller `\\` för att skapa ett vanligt `\` i en sökväg - det gäller bara er som har en dator med Windows]
5. Det är möjligt i vissa operativsystem att manuellt söka sig fram till den sökväg vi vill använda oss av. Detta görs då med funktionen `file.choose()`.
6. Använd `setwd()` och `mittWorkingDirectory` för att ändra ditt working directory i R.
7. Använd `getwd()` för att se att sökvägen har ändrats.

5.2 .csv-filer och .txt-filer

Som en första steg ska vi pröva att importera csv-filer och txt-filer. Vi ska nu pröva att läsa in filen `Apple.txt` som du kan ladda ned [\[här\]](#). Vi ska också pröva att läsa in `google.csv`, denna fil kan du ladda ned [\[här\]](#).

1. Använd följande kod i R för att läsa in och studera filen “`Apple.txt`”. Observera att koden nedan kräver att `Apple.txt` ligger i din working directory. Vad betyder `sep=";"` och `header=TRUE`? [Tips: `?read.table`]

```
# Read data
apple <- read.table(file="Apple.txt", sep=";", header=TRUE)
```

- (a) Studera den `data.frame` du läst in med funktionerna `head()` och `tail()`.
2. Upprepa uppgift för `google.csv` och spara datat som `google` men använd `read.csv()` eller `read.csv2()` (det finns olika funktioner för europeisk standard och amerikans standard för csv-filer) istället för `read.table()`. Vilken funktion fungerar för den aktuella csv-filen?
 3. För att exportera dataset gör man på ett liknande sätt med funktionerna `write.csv()`, `write.csv2()` och `write.table()`. Pröva att spara ned datasetet `apple` som en .csv-fil på detta sätt.

```
write.csv(apple, file="Apple.csv")
```

4. Pröva nu att spara ned `google` som en textfil med `write.table()`.

5.3 .Rdata-filer

Rdata-filer är troligtvis det mest effektiva sättet av alla att spara data som filer (jmf med SAS, SPSS, Excel och csv). Det är R:s dataformat och bygger på en komprimering av materialet. Fördelen är att vi också kan spara flera R-objekt i en och samma Rdata-fil. För att arbeta med .Rdata-filer använder vi oss av `save()` och `load()`.

1. Pröva att spara datasetet `apple` i R-format som `Apple.RData` i din working directory.

```
save(apple, file="Apple.Rdata")
```

2. Pröva att spara både `apple` och `google` som `storebror.RData`.
3. Använd `save.image()` för att spara ned allt det du har i ditt “Global enviroment” som `alltJagHar.RData`.

```
save.image(file="alltJagHarData.Rdata")
```

4. Använd `dir()` för att se att filerna har sparats korrekt i ditt workspace.
5. Använd `ls()` to för att se vilka variabler som finns i R:s “workspace”.
6. Rensa det du har i ditt workspace med `rm(list=ls())`.
7. Ladda filen `apple.RData` med funktionen `load()`. Vilka objekt har du laddat in i R?
8. Rensa ditt Global enviroment igen med `rm()`. Ladda filen `storebror.RData` med funktionen `load()`. Vilka objekt har du laddat in i R?
9. Rensa ditt Global enviroment igen med `rm()`. Ladda filen `alltJagHar.RData` Vilka objekt har du laddat in i R?

Del II

Inlämningsuppgifter

Tips!

Inlämningsuppgifterna innebär att konstruera funktioner. Ofta är det bra att bryta ned programmeringsuppgifter i färre små steg och testa att det fungerar i varje steg.

1. Lös uppgiften med vanlig kod direkt i R-Studio (precis som i datorlaborationen ovan) utan att skapa en funktion.
2. Testa att du får samma resultat som testexemplen.
3. Implementera koden du skrivit i 1. ovan som en funktion.
4. Testa att du får samma resultat som i testexemplen, nu med funktionen.

Automatisk återkoppling med markmyassignment

Som ett komplement för att snabbt kunna få återkoppling på de olika arbetsuppgifterna finns paketet `markmyassignment`. Med detta är det möjligt att direkt få återkoppling på uppgifterna i laborationen, oavsett dator. Dock krävs internetanslutning.

För att installera `markmyassignment` krävs paketet `devtools` (som därför först måste installeras):

```
> install.packages("devtools")
> devtools::install_github("MansMeg/markmyassignment")
```

För att automatiskt återkoppla en laboration behöver du först ange vilken laboration det rör sig om på följande sätt:

```
> library(markmyassignment)
> set_assignment("[assignment path]")
```

där `[assignment path]` är en adress du får av läraren till varje laboration.

För att se vilka uppgifter som finns i laborationen kan du använda funktionen `show_tasks()` på följande sätt:

```
> show_tasks()
```

För att få återkoppling på en uppgift använder du funktionen `mark_my_assignment()`. För att rätta samtliga uppgifter i en laboration gör du på följande sätt:

```
> mark_my_assignment()
```

Tänk på att uppgifterna som ska kontrolleras måste finnas som funktioner i R:s globala miljö. Du kan också kontrollera en eller flera enskilda uppgifter på följande sätt:

```
> mark_my_assignment(tasks="foo")
> mark_my_assignment(tasks=c("foo", "bar"))
```

Det går också att rätta en hel R-fil med samtliga laborationer. Detta är bra att göra innan du lämnar in din laboration. För att rätta en hel fil gör du på följande sätt:

```
> mark_my_assignment(mark_file = "[my search path to file]")
```

där `[my search path to file]` är sökvägen till din fil.

Obs! När hela filer kontrolleras måste den globala miljön vara tom. Använd `rm(list=ls())` för att rensa den globala miljön.

Kapitel 6

Inlämningsuppgifter

För att använda `markmyassignment` i denna laboration ange:

```
library(markmyassignment)

Loading required package: methods
Loading required package: yaml
Loading required package: testthat
Loading required package: httr

lab_path <-
  "https://raw.githubusercontent.com/MansMeg/KursRprgm/master/Labs/Tests/d2.yml"
set_assignment(lab_path)

Assignment set:
D2 : Statistisk programmering med R: Lab 2
```

6.1 leap_year()

Den 29 februari är en skottdag i kalendern och inträffar var fjärde år som exempelvis 2004, 2008, 2012 and 2016. Det vill säga de år som är jämt delbara med fyra. År som är jämt delbara med 100 innehåller inte skottdagar om de inte samtidigt är jämt delbara med 400. Exempelvis innehöll året 1900 inte en skottdag medan år 2000 innehöll en skottdag.

Vi ska skapa en funktion som testar om en vektor av år är skottår eller ej och returnerar detta som en `data.frame`. Skapa en funktion som heter `leap_year()`. Funktionen ska ha argumentet `years` som ska vara en textvektor.

Exempel på hur du kan implementera funktionen:

1. Konvertera `years` till en numerisk vektor.
2. Använd den numeriska vektorn för att testa om varje givet år är ett skottår. Generera en logisk vektor som är `TRUE` om året är ett skottår.
3. Skapa en `data.frame` med två variabler, `years` och `leap_year`. Variabeln `years` ska innehålla de den konverterade numeriska vektorn `years` och `leap_year` ska innehålla en logisk indikator, `TRUE` om året är ett skottår och annars `FALSE`.

Här är testexempel på hur funktionen ska fungera:

```
> my_test_years <- c("1900", "1984", "1997", "2000", "2001")
> my_result <- leap_year(years = my_test_years)
> str(my_result)
```

```
'data.frame': 5 obs. of 2 variables:
 $ years      : num  1900 1984 1997 2000 2001
 $ leap_year: logi  FALSE TRUE  FALSE TRUE  FALSE

> my_result

  years leap_year
1  1900     FALSE
2  1984      TRUE
3  1997     FALSE
4  2000      TRUE
5  2001     FALSE
```

6.2 matrix_trace()

Diagonalmatriser och en matris spår (även kallad **trace**) är viktigt inom den linjära algebran. Mer information finns [här](#). Vi ska nu skapa en funktion för att beräkna en matris spår. Funktionen ska kallas `matrix_trace()` och ha argumentet `X`, som är en godtyckligt stor kvadratisk matris. En matris spår är summan av dess diagonalelement:

$$\text{tr}(A) = a_{11} + a_{22} + \dots + a_{nn} = \sum_{i=1}^n a_{ii}$$

Funktionen `matrix_trace()` ska returnera matrisens spår som ett numeriskt värde.

Exempel på hur du kan implementera funktionen:

1. Sätt värdena som inte ligger på diagonalen till 0. [**Tips!** `upper.tri()`, `lower.tri()`, `diag()`]
2. Gör om matrisen till en vektor och summera värdena.

Här är testexempel på hur funktionen ska fungera:

```
> A <- matrix(2:5, nrow=2)
> matrix_trace(X = A)

[1] 7

> B <- matrix(1:9, nrow=3)
> matrix_trace(X = B)

[1] 15
```

6.3 fast_stock_analysis()

Vi ska nu skapa en funktion för att göra en snabb analys av ett dataset som finns sparad som `.csv`. Detta är ett exempel på användningsområde för funktioner i R. Mycket data kommer in löpande och då kan det vara så att vissa standardanalyser vill vi göra snabbt med en förprogrammerad funktion. Vi ska skapa en funktion `fast_stock_analysis()` med argumentet `file_path` och `period_length`. Syftet är att snabbt analysera de senaste dagarnas aktiekurs.

Funktionen ska läsa in en `.csv` - fil som anges av argumentet `file_path` och returnera en lista med de namngivna listelementen `total_spridning`, `medel_slutpris`, `slutpris_opp` och `datum`.

Exempel på hur du kan implementera funktionen:

1. Läs in data (csv) med argumentet `file_path` (innehåller både filnamn och sökväg). Använd funktionen `read.csv()`. [**Tips!** tänk på `stringsAsFactors` innebär att datumvariablerna blir en faktorvariabel].

Obs! `file_path` ska bara innehålla sökvägen till filen, filen ska läsas in inne i funktionen.

2. Plocka ut de senaste `period_length` antal dagar från datasetet (anta att de senaste aktiekurserna är högst upp).
3. Räkna ut de värden som ska returneras av funktionen:
 - (a) `total_spridning` (ett numeriskt element) är skillnaden mellan det högsta värdet på `High` och det lägsta värdet på `Low` under perioden.
 - (b) `medel_slutpris` (ett numeriskt element) är det genomsnittliga slutpriset under perioden.
 - (c) `slutpris_upp` (ett logiskt element) är ett logiskt värde som anger `TRUE` om slutpriset första dagen under perioden är lägre än slutpriset den sista dagen under perioden.
 - (d) `datum` (vektor med två textelement) ska innehålla det första och det sista datumet för perioden. **OBS!** Detta ska vara en textvektor, inte en faktor.
4. Sätt ihop dessa värden till en namngiven lista med namnen ovan.

Här är testexempel på hur funktionen ska fungera (**Obs!** Detta är var min fil ligger, du behöver ange din egen sökväg):

```
appleFilePath <- "C:/minRkurs/filer/AppleTest.csv"
```

```
myList1 <- fast_stock_analysis(file_path = appleFilePath, period_length=5)
str(myList1)
```

```
List of 4
 $ total_spridning: num 11.8
 $ medel_slutpris : num 425
 $ slutpris_upp   : logi FALSE
 $ datum          : chr [1:2] "2012-01-24" "2012-01-18"
```

```
myList2 <- fast_stock_analysis(file_path = appleFilePath, period_length=10)
str(myList2)
```

```
List of 4
 $ total_spridning: num 12.7
 $ medel_slutpris : num 424
 $ slutpris_upp   : logi FALSE
 $ datum          : chr [1:2] "2012-01-24" "2012-01-10"
```

Grattis! Nu är du klar!