

# Datorlaboration 7

Josef Wilzén och Måns Magnusson

2 mars 2016

---

## Instruktioner

- Denna laboration ska göras i grupper om **två och två**. Det är viktigt för gruppindelningen att inte ändra grupper.
  - En av ska vara **navigatör** och den andra **programmerar**. Navigatörens ansvar är att ha ett helhetsperspektiv över koden. Byt position var 30:e minut. Båda ska vara engagerade i koden.
  - Det är tillåtet att diskutera med andra grupper, men att plagiera eller skriva kod åt varandra är **inte tillåtet**.
  - Använd inte å, ä eller ö i variabel- eller funktionsnamn.
  - Utgå från laborationsfilen, som går att ladda ned [här](#), när du gör inlämningsuppgifterna.
  - Spara denna som labb[no]\_grupp[no].R , t.ex. labb5\_grupp01.R om det är labb 5 och ni tillhör grupp 01. Ta inte med hakparenteser eller stora bokstäver i filnamnet. Denna fil ska laddas upp på LISAM och ska **inte** innehålla något annat än de aktuella funktionerna, namn-, ID- och grupp-variabler och ev. kommentarer. Alltså **inga** andra variabler, funktionsanrop för att testa inlämningsuppgifterna eller anrop till markmyassignment-funktioner. Om ni ska lämna i kompletteringar på del 2, döp då dessa till labb5\_grupp01\_komp1.R om det är första kompletteringstillfället. Se kurshemsidan för mer information om kompletteringar.
  - Laborationen består av två delar:
    - Datorlaborationen
    - Inlämningsuppgifter
  - I laborationen finns det extrauppgifter markerade med \*. Dessa kan hoppas över.
  - Deadline för labben framgår på [LISAM](#)
-

# Innehåll

<b>I</b>	<b>Datorlaboration</b>	<b>3</b>
<b>1</b>	<b>Enklare statistisk analys</b>	<b>4</b>
1.1	Enklare statistiska metoder mm . . . . .	4
1.1.1	Kombinatorik . . . . .	4
1.1.2	Korstabulering och $\chi^2$ -tester . . . . .	4
1.1.3	t-test . . . . .	5
1.1.4	Sambandsmått . . . . .	5
1.1.5	Beskrivande statistik . . . . .	6
1.1.6	Beskrivande statistik . . . . .	6
1.2	* Extraproblem . . . . .	7
<b>2</b>	<b>Introduktion till linjär regression</b>	<b>8</b>
2.1	Anpassa en regressionsmodell . . . . .	8
2.2	Analysera resultatet från en linjär regression . . . . .	9
2.2.1	Använda parametrar och resultat för vidare analys . . . . .	10
2.3	Tester och diagnostik . . . . .	11
2.3.1	Anscombes data . . . . .	12
<b>3</b>	<b>Housing data</b>	<b>13</b>
<b>4</b>	<b>Texthantering och regular expression i R med stringr</b>	<b>15</b>
<b>II</b>	<b>Inlämningsuppgifter</b>	<b>16</b>
<b>5</b>	<b>Inlämningsuppgifter</b>	<b>18</b>
5.1	wordcount() . . . . .	18
5.2	henify() . . . . .	19
5.3	diagonalize_matrix() . . . . .	20
5.4	my_grouped_test() . . . . .	21

# Del I

# Datorlaboration

# Kapitel 1

## Enklare statistisk analys

### 1.1 Enklare statistiska metoder mm

#### 1.1.1 Kombinatorik

1. Det finns inbyggda funktioner i R för kombinatorik. Testa att köra `?Special`. Leta reda på `factorial()` och `choose()` och läs om dem.
2. Faktulet: Beräkna nu  $3!$ ,  $6!$ , och  $12!$  med funktionen `factorial()`.
3. Binomialkoefficienter: Räkna nu ut följande  $\binom{10}{2}$ ,  $\binom{4}{2}$  och  $\binom{20}{5}$  med funktionen `choose()`.
4. Skapa nu en egen funktion för binomialkoefficienter utan att använda `choose()`. Tips `?factorial()`
5. Nu ska ni implementera en funktion som ska beräkna täthetsfunktionen för binomalfördelningen. Titta i `?dbinom` och se hur tätheten beräknas. Ni kan sedan använda `dbinom()` för att se om funktionen räknar rätt. Testa med några olika värden för `n` och `p`.

#### 1.1.2 Korstabulering och $\chi^2$ -tester

1. Vi börjar med att läsa in det interna datasetet `iris` med `data(iris)` i R. Vi ska nu använda detta dataset för att pröva att analysera data i R.

```
data(iris)dummyvariabler
```

2. Som ett första steg vill vi pröva att producera korstabeller. I `iris` finns bara en kategorisk variabel, därför klassindlear vi två kontinuerliga variabler på följande sätt.

```
iris$Petal.Length.Cat <- cut(iris$Petal.Length, breaks=3)
iris$Sepal.Length.Cat <- cut(iris$Sepal.Length, breaks=3)
```

3. Vi börjar med att skapa en korstabell på följande sätt:

```
table(iris$Petal.Length.Cat, iris$Species)
```

4. Vill vi använda flera kategoriska variabler med `ftable()`:

```
ftable(iris$Petal.Length.Cat, iris$Sepal.Length.Cat, iris$Species)
```

5. För att göra ett  $\chi^2$ -test använder vi funktionen `chisq.test()`. Funktionen behöver en tabell att testa, så vi skapar och sparar tabellen ovan och testar den sedan..

```
tab <- table(iris$Petal.Length.Cat, iris$Species)
chisq.test(tab)
```

6. Om vi tittar på tabellen ovan är det många värden som är 0 (d.v.s. mindre än 5). Då behöver vi korrigera vårt test med **Yates korrektion**. Detta kan vi göra i R genom att lägga till argumentet `correct=TRUE`.

```
chisq.test(tab, correct=TRUE)
```

7. Ett annat sätt är att använda **Fishers exakta test** istället. Det görs på följande sätt:

```
fisher.test(tab)
```

### 1.1.3 t-test

1. Vill vi jämföra två grupper avseende en kontinuerlig variabel använder vi funktionen `t.test()`. Inledningsvis kan vi testa om `Sepal.Length` för `iris versicolor` är mindre 6. Vi börjar med att plocka ut elementen för de olika arterna:

```
versLength <- iris$Sepal.Length[iris$Species=="versicolor"]
t.test(x=versLength, alternative="greater", mu=6)
```

2. Om vi nu vill testa om skillnaden mellan två blomsterarter är olika anger vi två vektorer, en för varje art:

```
virginLength <- iris$Sepal.Length[iris$Species=="virginica"]
t.test(x=versLength, y=virginLength)
```

### 1.1.4 Sambandsmått

För att studera samband mellan två eller flera kontinuerliga variabler studerar vi ofta korrelation och kovarians.

1. För att beräkna kovarians och korrelation används `cov()` och `cor()`.

```
cor(iris$Petal.Length, iris$Petal.Width)
cov(iris$Petal.Length, iris$Petal.Width)
```

2. Vi kan också enkelt skapa kovarians- och korrelationsmatriser på samma sätt:

```
cor(iris[,1:4])
cov(iris[,1:4])
```

3. Vill vi göra ett enkelt hypotestest för korrelationen använder vi `cor.test()`:

```
cor.test(iris$Petal.Length, iris$Petal.Width)
```

### 1.1.5 Beskrivande statistik

1. Hitta det högsta och minsta värdet i `iris` (för alla variabler). Ta reda på vilken rad dessa värden finns på med relationsoperatoren `==` och `which.max()`.
  - (a) Beräkna medelvärden för alla kolumnerna med `colMeans()`.
  - (b) Beräkna nu kvartiler för `Petal.Width` med funktionen `quantiles()`. Beräkna den 1 och 99 procentiga percentilen? [**Tips!** `?quantile`]
  - (c) Beräkna nu kvartiler för samtliga variabler.
  - (d) Testa nu att använda funktionen `summary()` på `Petal.Width` först och sedan på hela datasetet. Vad får du för resultat?
2. Skapa en logisk vektor som anger om en variabeln `Petal.Width` är större än 2. Spara denna variabel som `small` på följande sätt.
3. Använd `table()` för att se vilka arter (variabeln `Species`) som är `small`. För att beräkna kovarians och korrelation används `cov()` och `cor()`.

```
cor(iris$Petal.Length, iris$Petal.Width)
cov(iris$Petal.Length, iris$Petal.Width)library(markmyassignment)
```

4. Vi kan också enkelt skapa kovarians- och korrelationsmatriser på samma sätt:

```
cor(iris[,1:4])
cov(iris[,1:4])
```

5. Vill vi göra ett enkelt hypotestest för korrelationen använder vi `cor.test()`:

```
cor.test(iris$Petal.Length, iris$Petal.Width)
```

### 1.1.6 Beskrivande statistik

1. Hitta det högsta och minsta värdet i `iris` (för alla variabler). Ta reda på vilken rad dessa värden finns på med relationsoperatoren `==` och `which.max()`.
  - (a) Beräkna medelvärden för alla kolumnerna med `colMeans()`.
  - (b) Beräkna nu kvartiler för `Petal.Width` med funktionen `quantiles()`. Beräkna den 1 och 99 procentiga percentilen? [**Tips!** `?quantile`]
  - (c) Beräkna nu kvartiler för samtliga variabler.
  - (d) Testa nu att använda funktionen `summary()` på `Petal.Width` först och sedan på hela datasetet. Vad får du för resultat?
2. Skapa en logisk vektor som anger om en variabeln `Petal.Width` är större än 2. Spara denna variabel som `small` på följande sätt.
3. Använd `table()` för att se vilka arter (variabeln `Species`) som är `small`.

## 1.2 \* Extraproblem

1. Skapa en funktion som beräknar värdet på en hypergeometrisk fördelning.
2. Skapa en funktion som beräknar värdet på en Geometrisk fördelning.
3. Pokerhänder: Räkna ut sannolikheten för ett par, triss och "Royal flush" i en pokerhand på 5 kort. Se här för mer info.
4. I vissa fall vill vi simulera data från en given sannolikhetsmodell. Det kan exempelvis vara en linjär modell som ser ut på följande sätt:

$$y_i = \alpha + \beta x_i + \epsilon_i$$

där  $\epsilon_i \sim \mathcal{N}(0, \sigma)$ . Detta görs enklast i flera steg. I detta fall simulerar jag även  $x_i$  samt sätter  $\alpha = 2, \beta = 4, \sigma = 1$  och  $n = 100$ .

```
alpha <- 2
beta <- 4
sigma <- 1
n <- 100

x <- rnorm(n)
y <- alpha + beta*x + rnorm(n, sd=sigma)
```

5. Kör koden ovan och visualisera det simulerade datamaterialet i ett spridningsdiagram [**Tips!** `plot()`]
6. Prova lite olika värden för  $\sigma$ ,  $\beta$  och  $\alpha$  och visualisera de olika datamaterialen.
7. Nu ska vi utöka modellen ovan till:  $y_i = \alpha + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i$  Kör koden nedan. Testa nu att ändra  $\sigma$ ,  $\beta_1$ ,  $\beta_2$  och  $\alpha$ . Testa att ändra värdet på  $\sigma$  på ett sådant sätt att den kvadratiske sambandet blir väl synligt och blir svårt att se.

```
alpha <- 2
beta <- c(2,4)
sigma <- 1
n <- 100

x <- rnorm(n)
y <- alpha + beta[1]*x+beta[2]*x^2 + rnorm(n, sd=sigma)
```



## Kapitel 2

# Introduktion till linjär regression

Denna laboration kommer inte gå in i teorin bakom (multipel) linjär regression utan kommer fokusera hur man anpassar regressionmodeller, analyserar resultatet och gör diagnostiska tester i R.

## 2.1 Anpassa en regressionsmodell

Den vanliga regressionmodellen bygger på modellen

$$y_i = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \epsilon_i$$

eller med matrisnotation

$$\mathbf{y} = \mathbf{B}\mathbf{x} + \epsilon$$

där  $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2)$  där de okända parametrarna är  $\beta$  samt  $\sigma$  i modellen och baserat på våra data vill vi uppskatta dessa parametrar.

I R (och till skillnad mot de flesta statistikprogram) skiljer vi på att anpassa (eller skatta) en modell och studera resultatet från modellen eller använda den för ex. prediktion. För att anpassa en modell använder vi funktionen `lm()`. Det gör att vi kan anpassa en linjär modell och sedan spara den som ett vanligt R-objekt. Sedan kan vi studera detta objekt på ett stort antal sätt, skriva egna funktioner för specifik analys, eller för att grafiskt visualisera modellen.

1. Vi börjar med att läsa in datasetet **Prestige** som finns i paketet **car**. Vi behöver också paketet **MASS**. Installera dessa paket om du inte har dem installerade.

```
library(car)
data(Prestige)
library(MASS)
```

2. Läs på kort om de variabler som finns i datasetet med `?Prestige`.
3. Börja med att visualisera sambandet mellan `prestige` och `income`. [**Tips!** `plot()`]
4. Vi ska nu anpassa vår första linjära regressionsmodell. För att anpassa en modell i R behöver vi ange två saker, dels en **formula** som beskriver hur modellen ser ut, och sedan vilket dataset som innehåller variablerna vi vill ha i vår modell. För att anpassa en linjär regression med inkomst som oberoende variabel gör vi på följande sätt:

```
minModell <- lm(prestige ~ income, data=PreStige)
minModell

Call:
lm(formula = prestige ~ income, data = Prestige)
```

```
Coefficients:
(Intercept)      income
    27.1412      0.0029
```

- Om vi tittar på det resulterande objektet ser vi regressionskoefficienternas värden. Detta är bra för en snabb koll, men senare kommer vi gå in mer på hur vi kan få ut mer utförliga resultat.
- `prestige ~ income` är ett objekt av klass `formula`. `formula`-objekt används i många funktioner i R för att specificera statistiska modeller på ett flexibelt sätt. Testa att köra `class(prestige ~ income)` och `str(prestige ~ income)`. Likt andra objekt kan `formula`-objekt sparas och manipuleras. Kör koden nedan.

```
x<-prestige ~ income
minModell1 <- lm(x, data=Prestige)
minModell1
```

- Det går också att bara ange vektorer (de behöver inte heller ligga i samma `data.frame`):

```
minModell2 <- lm(Prestige$prestige ~ Prestige$income)
```

- Vill vi lägga till flera variabler (andel kvinnor, utbildning) gör vi på följande sätt:

```
minModell3 <- lm(prestige ~ income + women + education, data=Prestige)
```

- Vi kan på detta sätt enkelt lägga till ett stort antal variabler. Som standard så inkluderas alltid en intercept i modellen, vill vi ta bort denna använder lägger vi till `-1`:

```
minModell4 <- lm(prestige ~ income + women - 1, data=Prestige)
```

- Nu kommer också fördelarna med att ha definierat faktorvariabler. Läger vi in en faktorvariabel förstår R detta automatiskt och “under the hood” skapas dummyvariabler för vilka koefficienter skattas. Dummyvariabler kommer att förklaras närmare i senare kurser om regression.

```
minModell5 <- lm(prestige ~ income + type, data=Prestige)
```

- Till sist kan det vara så att vi vill lägga till interaktionseffekter i modellen. Detta görs enkelt med `:` på följande sätt (detta inkluderar både additiva och multiplikativa effekter):

```
minModell6 <- lm(prestige ~ income:women, data=Prestige)
```

## 2.2 Analysera resultatet från en linjär regression

Nu har vi anpassat (och smygtittat på) lite olika modeller baserat på datasetet `Prestige`. Vi ska nu studera de resultat vi fått lite mer. Nu har vi stor nytta av R:s objektorienterade uppbyggnad och generiska funktioner.

- Vi börjar med att använda funktionen `summary()`. Se exemplet nedan:

```
summary(minModell)

Call:
lm(formula = prestige ~ income, data = Prestige)

Residuals:
    Min       1Q   Median       3Q      Max
-33.01  -8.38  -2.38   8.43  32.08

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.71e+01   2.27e+00   12.0   <2e-16 ***
income       2.90e-03   2.83e-04   10.2   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.1 on 100 degrees of freedom
Multiple R-squared:  0.511, Adjusted R-squared:  0.506
F-statistic: 105 on 1 and 100 DF, p-value: <2e-16
```

2. Med denna får vi en sammanfattning av de flesta resultat i modellen. Prova denna funktion på `minModell13`. Hitta följande storheter i sammanfattningen av modellen:  $\beta$ ,  $\sigma$ ,  $R^2$ ,  $F$ -statistikan samt  $p$ -värdena för de olika  $\beta$ -koefficienterna.
3. Prova att analysera modell 5 och 6 på samma sätt. Hur ser en kategorisk variabel samt interaktionseffekter ut i R?
4. Funktionen `summary()` ger en bra bild av resultatet, men vi vill ofta också studera en ANOVA-tabell för vår modells ingående variabler. För detta används funktionen `anova()`. Prova den på modellerna 3, 5 och 6.
5. De flesta (icke-bayesianska) statistiker och forskare är mycket förtjusta i  $p$ -värden. För att få ut  $p$ -värden till ANOVA-tabellen använder vi oss av argumentet `test='Chisq'`. Prova att på detta sätt testa för variabler i modell 5.
6. Vi kan också inkludera flera modeller i en ANOVA-tabell. Vad ger det för resultat?

```
anova(minModell, minModell13, test="Chisq")
```

## 2.2.1 Använda parametrar och resultat för vidare analys

Vill vi använda vissa speciella delar av en modell kan vi plocka ut delar från modellen med olika funktioner. Exempelvis kanske vi är intresserad av att använda  $\beta$ -koefficienterna i modellen till något annat. Eller använda modellen för att göra prediktioner på nya data.

1. Prova att använda funktionen `coef()` på modellobjekt 3 ovan. Prova att spara ned resultatet som ett nytt objekt. Vad får du för resultat? Jämför med `print()`.
2. På ett liknande sätt kan vi snabbt få ut alla residualer (om vi vill studera dessa) med funktionen `resid()`. Prova denna funktion på modell 3 ovan och plotta residualerna i ett histogram. Är residualerna normalfördelade? **[Tips! `hist()`]**
3. Prova att med hjälp av residualvektorn och relationsoperatorer ta fram vilket yrke har den största negativa residualen (d.v.s. lägst prestige kontrollerat för utbildning, inkomst och könsfördelning). **[Tips! `which.min()`]**
4. Vi kan också få ut de predicerade värdena för varje observation med `predict()`. Prova att på detta sätt se vilket yrke som har den högsta respektive lägsta förväntade prestige. **[Tips! `which.max()`]**

5. Vi kan också använda `predict()` för att skapa prediktioner på nya data. Då behöver vi ta ett nytt dataset (men med samma variabelnamn och variabeltyper) och ange detta data med argumentet `newdata`. Prova att ta de fem första raderna i datasetet `Prestige` och spara det som `newPrestige`. Prova att predicera variabeln `prestige` för detta dataset med modell 6.

## 2.3 Tester och diagnostik

I linjär regression görs ett stort antal antagande om i modellen som ligger till grund för att kunna dra slutsatser från materialet. Nedan följer ett antal tester och visualiseringar för att diagnostisera ett antal centrala antaganden i linjär regression.

Observera att syftet med denna del är att testa lite olika funktionalitet i R, för mer fördjupad genomgång av de olika antagandena och hur dessa problem avhjälpes se dokumentationen till funktionerna eller i litteratur på området (en bra sammanfattning är [\[här\]](#)).

Välj en godtycklig modell ovan (eller skapa en egen ny modell) och utför följande diagnostik:

1. Det första och enklaste sättet att diagnostisera vår modell är att vi använder funktionen `plot()` på vårt modellobjekt. Prova `plot()` på modell 3, 5 och 6.
2. Nedan finns lite olika diagnostiska verktyg och kodexempel. Prova på detta sätt att...

- (a) Identifiera uteliggare

```
outlierTest(minModell)
qqPlot(minModell)
leveragePlots(minModell)
```

- (b) Identifiera observationer med starkt inflytande på modellen

```
avPlot(minModell)
influencePlot(minModell)
```

- (c) Utvärdera linjäritetsantagande för regressionskoefficienterna

```
crPlots(minModell)
ceresPlots(minModell)
```

- (d) Studera multikollinearitet mellan regressionskoefficienterna

```
vif(minModell)
```

- (e) Oberoende felterm (framförallt för tidsserieregression)

```
durbinWatsonTest(minModell)
```

- (f) Residualernas fördelning

```
qqPlot(minModell)
```

- (g) Konstant varians (homoscedasticitet)

```
ncvTest(minModell)
spreadLevelPlot(minModell)
```

3. Prova att baserat på dessa tester att anpassa den modell för variabeln `prestige` som du själv tror mest på. Vad är dina slutsatser?

### 2.3.1 Anscombes data

Vi ska nu pröva ett klassiskt exempel när det gäller linjär regression, **anscombes data**. Materialet består av fyra  $x$ -variabler och fyra  $y$ -variabler där materialet ser mycket olika ut, även om de enskilda regressionsmodellerna har exakt samma resultat.

1. Börja med att läsa in materialet i R med `data()`.

```
data(anscombe)
```

2. Anpassa nu följande fyra regressionsmodeller i R utan att plotta materialet.

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 x_1 + \epsilon \\y_2 &= \beta_0 + \beta_1 x_2 + \epsilon \\y_3 &= \beta_0 + \beta_1 x_3 + \epsilon \\y_4 &= \beta_0 + \beta_1 x_4 + \epsilon\end{aligned}$$

3. Studera koefficienterna i modellerna. De ska vara nästan identiska.
4. Pröva nu att plotta datamaterialet och använd de diagnostiska verktygen ovan. Vilka antaganden är problematiska i respektive modell, och vilka diagnostiska verktyg fångar upp detta?

## Kapitel 3

# Housing data

1. Ni ska nu analysera datamaterialet HUS, som innehåller information om en mängd hus. Följande variabler finns i data:

- Försäljningspris (dollar)
- Bostadsyta (kvadratfot)
- Antal sovrum
- Antal badrum
- Förekomst av luftkonditionering, 1 = luftkonditionering finns, 0 annars
- Antal bilar som garaget är konstruerat för
- Förekomst av pool, 1 = pool finns, 0 annars
- Byggår
- Tomtstorlek (kvadratfot)

2. Läs in datamaterialet “HUS.csv” och spara det som HUS. Det finns även ett dataset “HUS\_eng.csv”, som har engelska namn på variablerna men innehåller samma data. Materialet finns att tillgå [\[här\]](#).

3. Gör följande med HUS

- (a) Plotta en boxplot över variabeln **Försäljningspris**. Ta fram beskrivande statistik med `summary()` för **Försäljningspris**. Det verkar finnas en del outliers (extremt stora värden), dessa vill vi ta bort från data, kör följande kod:

```
# ta bort alla hus som har pris större än 3:e kvartilen:  
index<-HUS[,1]<quantile(HUS[,1])[4]  
HUS<-HUS[index,]
```

- (b) Plotta ett histogram för **Försäljningspris** med `breaks=40`, (bonusfråga: ser fördelningen symmetrisk ut?)
- (c) Beräkna ett tvåsidigt konfidensintervall (KI) med  $\alpha = 0.05$  för **Försäljningspris** (tips `?t.test()`) spara i `testPris`.
- (d) Välj ut KI från `testPris`. tips: `?t.test()` och läs under rubriken “Value”. Kör sedan `str(testPris)`. Testa `class(testPris)`
- (e) Beräkna ett tvåsidigt KI med  $\alpha = 0.10$  för **Försäljningspris**
- (f) Beräkna ett enkelsidigt (undre) KI med  $\alpha = 0.01$  för **Försäljningspris**
- (g) Kör koden nedan, vad blir resultatet? Hur ska medelvärdet för variabeln **Luftkonditionering** tolkas?

```
summary(HUS)
```

4. Skapa följande frekvenstabeller från HUS (tips: `?table()` )
  - (a) För `Antal.sovrum`
  - (b) För `Luftkonditionering`
  - (c) Mellan variablerna `Antal.sovrum` och `Luftkonditionering`, spara som `sovLuftTab`. Testa `class(sovLuftTab)`
  - (d) Mellan variablerna `Antal.sovrum` och `Antal.badrum`
5. Kör `prop.table(sovLuftTab)` och `prop.table(sovLuftTab,margin=1)`. Vad händer med tabellen?
6. Beräkna fishers exakta test för tabellen `sovLuftTab`, använd  $\alpha = 0.05$ , vad är noll-hypotesen? Kan vi förkasta den? (tips: `?fisher.test()` )
7. Antag att variabeln `Försäljningspris` representerar en hel population med hus. Dra ett slumpmässigt stickprov med 20 hus utan återläggning. Beräkna ett tvåsidigt KI ( $\alpha = 0.01$ ) utifrån stickprovet för populationsmedelvärdet.
8. Antag nu att hela datasetet HUS är alla hus i en population. Dra ett stickprov slumpmässigt (dvs välj rader) på 40 hus utan återläggning. Gör följande beräkningar utifrån stickprovet:
  - (a) Numeriska variabler: Beräkna ett tvåsidigt KI med  $\alpha = 0.01$  för populationsmedelvärdet.
  - (b) Binära(0/1) variabler: Beräkna ett tvåsidigt KI med  $\alpha = 0.01$  för populationsandelen. Tips: `?prop.test()`, `?table()`

## Kapitel 4

# Texthantering och regular expression i R med stringr

Gör följande delar i *Handling and Processing Strings in R* av Gaston Sanchez.

**Kap 2**     Hela

**Kap 3**     3.1, 3.3

**Kap 4**     4.2.1 - 4.2.3

**Kap 5**     5 - 5.2.2, 5.2.6, 5.3.1-5.3.2

**Kap 6**     6-6.1.3, 6.2.2, 6.4 - 6.4.1, 6.4.3, 6.4.5, 6.4.7, 6.4.9 - 6.4.10

Boken finns fritt tillgänglig [\[här\]](#).



## Del II

# Inlämningsuppgifter

## Tips!

Inlämningsuppgifterna innebär att konstruera funktioner. Ofta är det bra att bryta ned programmeringsuppgifter i färre små steg och testa att det fungerar i varje steg.

1. Lös uppgiften med vanlig kod direkt i R-Studio (precis som i datorlaborationen ovan) utan att skapa en funktion.
2. Testa att du får samma resultat som testexemplen.
3. Implementera koden du skrivit i 1. ovan som en funktion.
4. Testa att du får samma resultat som i testexemplen, nu med funktionen.

## Automatisk återkoppling med markmyassignment

Som ett komplement för att snabbt kunna få återkoppling på de olika arbetsuppgifterna finns paketet **markmyassignment**. Med detta är det möjligt att direkt få återkoppling på uppgifterna i laborationen, oavsett dator. Dock krävs internetanslutning.

Information om hur du installerar och använder **markmyassignment** för att få direkt återkoppling på dina laborationer finns att tillgå [här](#).

Samma information finns också i R och går att läsa genom att först installera **markmyassignment**.

```
install.packages("markmyassignment")
```

Om du ska installera ett paket i PC-pularana så behöver du ange följande:

```
install.packages("markmyassignment", lib="sökväg till en mapp i din hemkatalog")
```

Tänk på att i sökvägar till mappar/filer i R i Windowssystem så används ‘\\’, tex ‘C:\\Users\\Josef’.

Därefter går det att läsa information om hur du använder **markmyassignment** med följande kommando i R:

```
vignette("markmyassignment")
```

Det går även att komma åt vignetten [här](#). Till sist går det att komma åt hjälpfilerna och dokumentationen i **markmyassignment** på följande sätt:

```
help(package="markmyassignment")
```

Lycka till!

## Kapitel 5

# Inlämningsuppgifter

För att använda `markmyassignment` i denna laboration ange:

```
library(markmyassignment)

Loading required package: methods
Loading required package: yaml
Loading required package: testthat
Loading required package: httr

lab_path <-
  "https://raw.githubusercontent.com/STIMALiU/KursRprgm/master/Labs/Tests/d7.yml"
suppressWarnings(set_assignment(lab_path))

Assignment set:
D7 : Statistisk programmering med R: Lab 7
```

### 5.1 wordcount()

Nu är uppgiften att skapa en funktion som ska kunna räkna hur många gånger olika ord förekommer i texten. Funktionen ska heta `wordcount()` och ha argumentet `text` som ska vara en `character`-vektor. Funktionen ska ta en text (i form av en text vektor) och returnera en `data.frame` med två variabler `word` (textvariabel) och `freq` (integervariabel).

I variabeln `word` ska respektive ord ingå, men med små bokstäver, och i variabeln `freq` ska frekvensen av orden framgå. Den `data.frame` som returneras ska vara sorterad efter variabeln `word`. Funktionen ska också skriva ut meningen "The most common word is '[ord]' and it occurred [antal] times." med `message()`.

**Tips!** `table()`

Nedan är ett förslag på hur ni kan implementera funktionen.

1. Läs in paketet i `stringr` i den aktuella R-sessionen. OBS: ej installera paketet.
2. Börja med att sätta ihop de olika textelementen till en textsträng, men denna gång använd mellanslag som avskiljare istället för `\n`.
3. Ta bort punkter och kommatecken i textsträngen.
4. Gör om alla ord till endast gemener.
5. Dela upp teckensträngen med `str_split()` för att få ut respektive ord. [**Tips!** Tänk på att du får ut en lista med denna funktion, inte en vektor. `unlist()` kan då vara till hjälp.]
6. Räkna respektive ord och skapa en `data.frame` med respektive ord i kolumn 1 och antalet förekomster av detta ord i kolumn 2. Döp kolumn 1 till "word", och kolumn 2 till "freq".
7. Sortera datasetet efter `word`.

8. Använd `str_c()` och `message()` för att baserat på datasetet ovan skriva ut följande mening “The most common word is '[ord]' and it occurred [antal] times.”.

9. Returnera din `data.frame`.

Kolla om testfallen nedan fungerar:

```
# Laddar ned testdata
library(downloader)
transtrommer_remote <-
  "https://raw.githubusercontent.com/STIMALiU/KursRprgm/master/Labs/DataFiles/transtrom.txt"
transtrommer_local <- paste0(getwd(), "/transtrom.txt")
download(url = transtrommer_remote, destfile = transtrommer_local)

# Test
text<-readLines("transtrom.txt")
worddata<-wordcount(text=text)

The most common word is 'the' and it occurred 8 times.

head(worddata[order(worddata[,2], decreasing=TRUE),])

  word freq
59 the    8
1  a      6
2  and    4
24 have   3
40 of     3
62 they   3

head(wordcount(text=rep("a",10)))

The most common word is 'a' and it occurred 10 times.

  word freq
1  a     10
```

## 5.2 henify()

Med hjälp av funktionerna i `stringr` ska ni skriva en funktion som ska byta ut “han” och “hon” i en text mot “hen”. Detta kan göras med hjälp av regular expressions. Det ska gå att göra denna operation med endast ett regular expression (om vi ignorerar versaler i hen). Det är dock inte ett måste att implementera detta med bara en rad kod.

Funktionen ska heta `henify(text)`

- argumentet `text` ska antingen ange sökvägen till den textfil som ska användas som då slutar på “.txt” eller vara en teckenvektor innehållande en text.

Arbetsordning:

1. Läs in paktet i `stringr` i den aktuella R-sessionen. OBS: ej installera paktet.
2. Iakttag följade fall:
  - (a) Om `text` är en sökväg till en fil så ska filen med texten läsas in som och sparas i en charactervektor. Detta kan du kolla med om de fyra sista tecknen är “.txt”.  
**Tips!** `str_sub()`, `readLines()`. Glöm inte att . är ett metatecken.
  - (b) Om första elementet i `text` inte slutar på “.txt” så ska `text` användas som en textvektor i resten av funktionen.
3. Använd nu `str_replace_all()` för att ersätta Han/han och Hon/hon med Hen/hen. Här behöver ni använda regular expressions. Iakttag följande:

- Tänk på att han/hon ska kunna börja med stor eller liten bokstav.
- Han/hon kan komma först i strängen, någonstans i mitten, eller sist.
- Vi ska inte välja ord där han/hon är en del av ordet, tex “storhandla” ska inte bli “storhendla” eller att “hona” ska blir “hena”.

4. Returnera den ändrade texten.

Kolla om testfallen nedan fungerar:

```
library(downloader)
transtrommer_remote <-
  "https://raw.githubusercontent.com/STIMaLiU/KursRprgm/master/Labs/DataFiles/transtrom2.txt"
transtrommer_local <- paste0(getwd(), "/transtrom2.txt")
download(url = transtrommer_remote, destfile = transtrommer_local)

# test 1:
henify(text="transtrom2.txt")

[1] "När hen kom ner på gatan efter kärleksmötet"
[2] "virvlade snö i luften."
[3] "Vintern hade kommit"
[4] "medan de låg hos varann."
[5] "Natten lyste vit."
[6] "Hen gick fort av glädje..."
[7] "Hela staden sluttade."
[8] "Förbipasserande leenden -"
[9] "alla log bakum uppgällda kragar."
[10] "Det var fritt!"
[11] "Och alla frågetecken började sjunga om Guds tillvaro."
[12] "Så tyckte hen!"

# test 2:
txt1<-c("Hon, hankar handskar, han", "handlar du honorarer?", "honartad hona han.")
txt1

[1] "Hon, hankar handskar, han" "handlar du honorarer?"
[3] "honartad hona han."

henify(txt1)

[1] "Hen, hankar handskar, hen" "handlar du honorarer?"
[3] "honartad hona hen."
```

### 5.3 diagonalize\_matrix()

Vi ska skapa en funktion, `diagonalize_matrix()`, som kan diagonalisera en godtycklig matris. Argumentet ska vara `X`. Funktionen ska först testa om matrisen är diagonaliserbar, d.v.s. om matrisens egenvektorer är linjärt oberoende (d.v.s. determinanten av egenvektorererna är skild från 0). Av numeriska skäl kan detta vara svårt att uppfylla. I denna uppgift ska därför determinanten avrundas till 10 decimaler för att testa om matrisen är diagonaliserbar.

Hur man diagonaliserar en matris framgår [\[här\]](#). Funktionen ska returnera en lista med de namngivna elementen `P`, `D` och `Pinv`.

Är matrisen inte diagonaliserbar ska funktionen avbrytas med meddelandet `''Matrix not diagonalizable.''`.

**Tips!** `eigen()`

```
A <- matrix(1:4,ncol=2)
diagonalize_matrix(X = A)
```

```

$P
      [,1]      [,2]
[1,] -0.56577 -0.90938
[2,] -0.82456  0.41597

$D
      [,1]      [,2]
[1,]  5.3723  0.00000
[2,]  0.0000 -0.37228

$Pinv
      [,1]      [,2]
[1,] -0.42223 -0.92305
[2,] -0.83697  0.57428

A <- matrix(c(0,1,0,0),ncol=2)
diagonalize_matrix(X = A)

Matrix not diagonalizable.

A <- matrix(c(4,1,-2,1),ncol=2)
diagonalize_matrix(X = A)

$P
      [,1]      [,2]
[1,]  0.89443  0.70711
[2,]  0.44721  0.70711

$D
      [,1] [,2]
[1,]    3    0
[2,]    0    2

$Pinv
      [,1]      [,2]
[1,]  2.2361 -2.2361
[2,] -1.4142  2.8284

```

## 5.4 my\_grouped\_test()

Nu ska ni skapa en funktion som ska beräkna gruppvisa konfidenstervall (KI) för en variabel. Innan ni börjar se till att HUS-data är inläst och kör koden nedan för att ta bort de extremt stora värdena:

```

# Download
file_path <-
  "https://raw.githubusercontent.com/STIMaLiU/KursRprgm/master/Labs/DataFiles/HUS.csv"
HUS <- repmis::source_data(file_path)

Downloading data from: https://raw.githubusercontent.com/STIMaLiU/KursRprgm/master/Labs/DataFiles/HUS.csv

SHA-1 hash of the downloaded data file is:
777f771c0493bca3910d619136aed9f4265a2a1d

# Small corrections (removing outliers)
index<-HUS[,1] < quantile(HUS[,1])[4]
HUS<-HUS[index,]

```

Funktion ska heta `my_grouped_test()` och ha argumenten:

- `data_vector` - är en numerisk vektor
- `my_groups` - är en factor/character-vektor som grupperar `dataVector`
- `alpha` - är signifikansnivån för intervallet, `alpha=0.05` ska ge ett 95 % konfidensintervall.

Funktionen ska returnera en matris `result` där raderna motsvarar grupperna i `my_groups` och har fyra kolumner: Undre gräns för KI, medelvärdet, övre gräns för KI och antal observationer i varje grupp. Se testfallen för namnen på kolumnerna. Raderna ska ha samma namn som grupperna `my_groups`.

Förslag till lösning:

1. Se till att `my_groups` är en faktor. Räkna ut hur många grupper som finns i `my_groups`. **Tips!** `?levels()` `?table()`
2. Skapa en tom matris av rätt storlek, kalla den `result`. Ge den lämpliga namn. **Tips!** `?colnames()`, `?rownames()`
3. Spara antalet observationer för varje grupp i den fjärde variabeln i `result`.
4. Använd `by()` kombinerat med `t.test()` för att beräkna gruppvisa KI, spara i `group_test`. Testa `?by()`, ni ser att det finns ett argument som heter `"..."` för funktionen `by()`. Dessa tre punkter kan ersättas med argument som behövs till funktionen `"FUN"`. Mer tips: `str('objekt från t.test')` och `?by` läs under rubriken `"value"` för att kolla vad `by()` returnerar.
5. Loopa över antalet grupper och välj ut KI och medelvärde för varje grupp från `group_test`. Spara på rätt ställen i `result`.
6. Returnera `result`.

Testa om testfallen nedan fungerar:

```
my_grouped_test(HUS[,1],HUS$Luftkonditionering,0.01)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
0	161468	173473	185479	82
1	213182	220556	227930	308

```
my_grouped_test(HUS[,2],HUS$Pool,0.10)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
0	1918.7	1955.5	1992.3	372
1	1890.6	2041.5	2192.4	18

```
# Chickwts-data
```

```
data(chickwts)
```

```
my_grouped_test(chickwts[,1],chickwts[,2],0.05)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
casein	282.64	323.58	364.52	12
horsebean	132.57	160.20	187.83	10
linseed	185.56	218.75	251.94	12
meatmeal	233.31	276.91	320.51	11
soybean	215.18	246.43	277.68	14
sunflower	297.89	328.92	359.95	12

*Nu är du klar!*